Laboratório 4 - Pipeline de NLP Tarefa de Classificação de Notícias

Diário de bordo

1) Inicialmente testamos 13 configurações/ajustes, sempre com a variável use_glove = True, no código fornecido pelo professor, obtendo os resultados abaixo:

- 1 embedding_size = 100 hidden_dim = 100 batch_size = 128 learning_rate = 0.001 dropout = (desabilitado) num_epochs = 100 optimizer = SGD
- training loss and accuracy

 train_acc

 val_acc

 70

 40

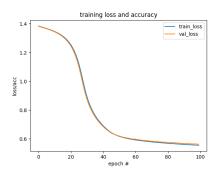
 20

 40

 66

 80

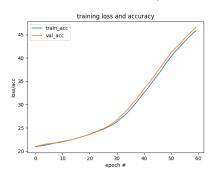
 100

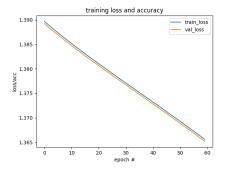


Comentários: depois de 60 épocas, os valores ficaram praticamente estáveis.

Vamos diminuir o nº de épocas e baixar a taxa de aprendizagem.

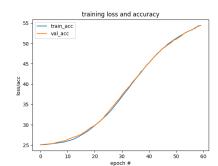
2 embedding_size = 100 hidden_dim = 100 batch_size = 128 learning_rate = **0.0001** dropout = (desbilitado) num_epochs = **60** optimizer = SGD

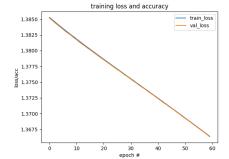




Comentários: acurácia diminuiu muito em relação ao 1º modelo. Vamos acrescentar poder (nodos) ao modelo.

3 embedding_size = 100 hidden_dim = **200** batch_size = 128 learning_rate = 0.0001 dropout = (desabilitado) num_epochs = 60 optimizer = SGD

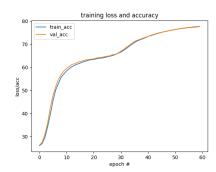


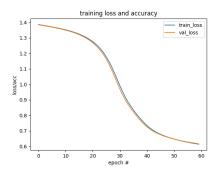


Comentários: acurácia melhorou em relação ao modelo anterior, mas ficou muito aquém do 1ª modelo.

Vamos aumentar a taxa de aprendizagem.

4 embedding_size = 100 hidden_dim = 200 batch_size = 128 learning_rate = **0.001** dropout = (desabilitado) num_epochs = 60 optimizer = SGD

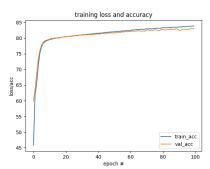


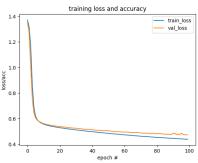


Comentários: praticamente os mesmos resultados do 1ª modelo apesar de mais poder computacional.

Vamos aumentar mais a taxa de aprendizagem.

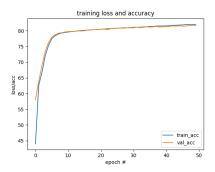
5 embedding_size = 100 hidden_dim = 200 batch_size = 128 learning_rate = **0.01** dropout = (desabilitado) num_epochs = 100 optimizer = SGD

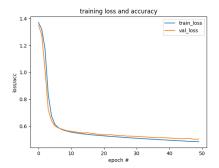




Comentários: praticamente os mesmos resultados anteriores. Vamos diminuir o nº de épocas.

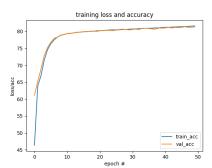
6 embedding_size = 100 hidden_dim = 200 batch_size = 128 learning_rate = 0.01 dropout = (desbilitado) num_epochs = **50** optimizer = SGD

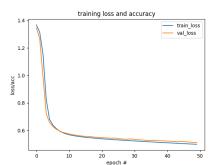




Comentários: praticamente os mesmos resultados anteriores. Vamos diminuir aumentar o poder da rede.

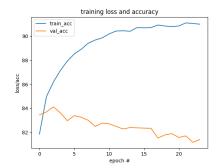
7 mbedding_size = 100 hidden_dim = **400** batch_size = 128 learning_rate = 0.01 dropout = (desabilitado) num_epochs = 50 optimizer = SGD

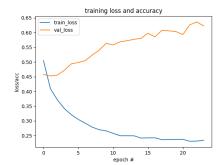




Comentários: praticamente em efeitos na acurácia. Vamos alterar o otimizador e diminuir o poder da rede.

8 embedding_size = 100 hidden_dim = **200** batch_size = 128 learning_rate = 0.01 dropout = (desabilitado) num_epochs = 50 (20) optimizer = **ADAM**

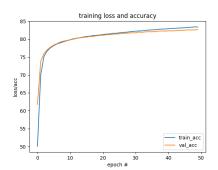


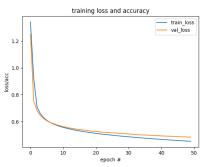


Comentários: de longe a maior acurácia, mas com overfitting. Paramos o treinamento com 20 épocas.

Vamos diminuir a taxa de aprendizagem em 3 ordens de grandeza.

9 embedding_size = 100 hidden_dim = 200 batch_size = 128 learning_rate = **0.00001** dropout = (desabilitado) num_epochs = 50 optimizer = ADAM

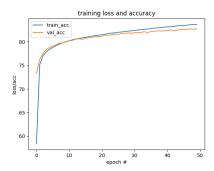


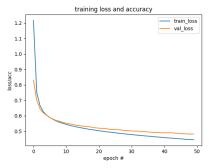


Comentários: o melhor resultado até aqui.

Vamos aumentar o poder da rede.

10 embedding_size = 100 hidden_dim = **400** batch_size = 128 learning_rate = 0.00001 dropout = (desabilitado) num_epochs = 50 optimizer = ADAM

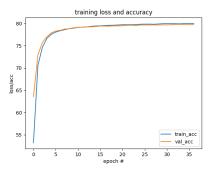


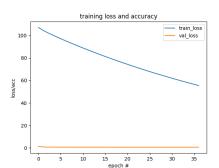


Comentários: praticamente os mesmos resultados que a rede anterior, apesar do maior poder (nodos).

Vamos fazer regularização L2.

11 embedding_size = 100 hidden_dim = 400 batch_size = 128 learning_rate = 0.00001 dropout = (desabilitado) num_epochs = 50 (35) optimizer = ADAM 12 regulariz. = 0.001

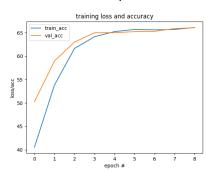


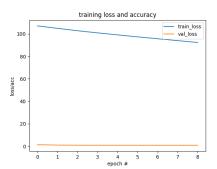


Comentários: Sem melhorar na acurácia, contudo a perda de validade fica zerada.

Vamos habilitar dropout.

12 embedding_size = 100 hidden_dim = 400 batch_size = 128 learning_rate = 0.00001 **dropout = 0.5** num_epochs = 50 (8) optimizer = ADAM l2_regularization = 0.001

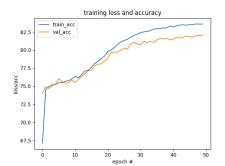


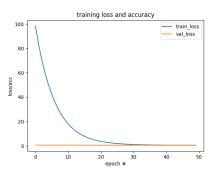


Comentários: além de piorar a acurácia, a perda de validade continuou zerada.

Vamos diminuir o poder da rede e aumentar a taxa de aprendizagem.

13 embedding_size = 100 hidden_dim = **200** batch_size = 128 learning_rate = **0.0001** dropout = 0.5 num_epochs = 50 optimizer = ADAM l2_regularization = 0.001





Comentários: Depois que utilizamos a regularização L2, a perda de validação ficou sempre zerada.

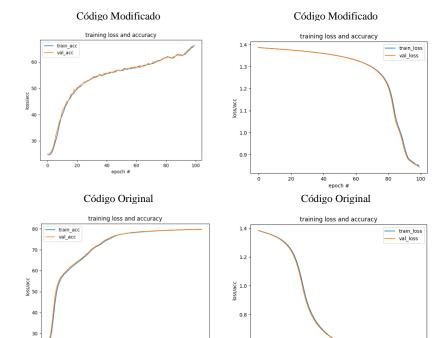
2) Implementados a modificação no código da etapa anterior – conforme solicitado no item 1 do laboratório, e escolhemos 5 configurações/ajustes realizados no item 1, de forma a permitir comparações dos resultados. Também calculamos as métricas de desempenho para os dados de testes dos modelos modificados.

embedding_size = 100

1 hidden_dim = 100
batch_size = 128
learning_rate = 0.001
dropout = (desabilitado)
num_epochs = 100
optimizer = SGD

Modificação:

features =
torch.mean(output,
dim=1)

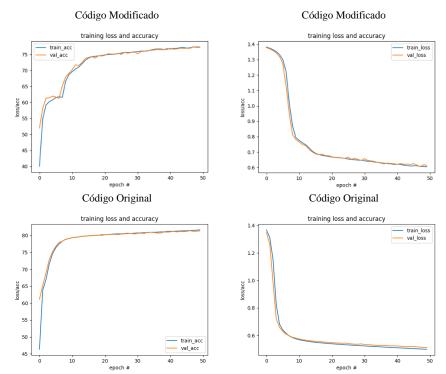


Comentários: Conforme gráficos acima, a acurácia do código original foi melhor que a do código modificado.

Test loss: 0.845932878766741 Test Accuracy: 66.64620535714283 7 embedding_size = 100 hidden_dim = **400** batch_size = 128 learning_rate = 0.01 dropout = (desabilitado) num_epochs = 50 optimizer = SGD

Modificação:

features =
torch.mean(output,
dim=1)



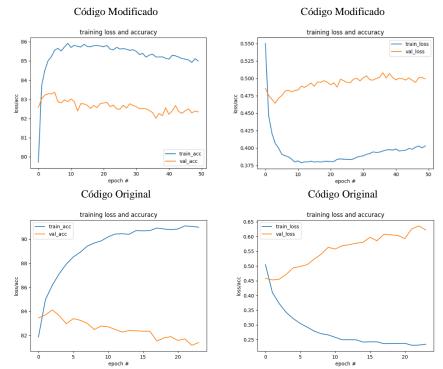
Comentários: Novamente, a acurácia do código original foi melhor que a do código modificado.

Test loss: 0.6029862405998364 Test Accuracy: 77.23214285714286

8 embedding_size = 100 hidden_dim = **200** batch_size = 128 learning_rate = 0.01 dropout = (desabilitado) num_epochs = 50 (20) optimizer = **ADAM**

Modificação:

features =
torch.mean(output,
dim=1)



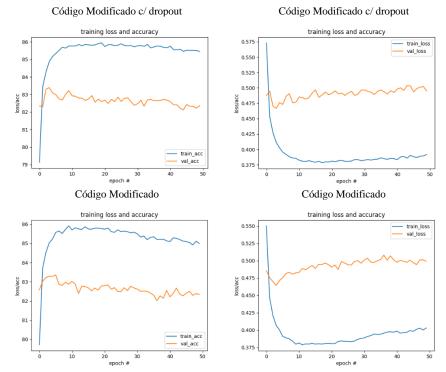
Comentários: Apesar da acurácia do modelo modificar ter ficado ligeiramente menor que o modelo original, o overfitting diminuiu.

Test loss: 0.4548148612890925 Test Accuracy: 83.57142857142854

Para este modelo habilitamos o dropout para tentar diminuir o overfitting.

8.1 embedding_size = 100 hidden_dim = 200 batch_size = 128 learning_rate = 0.01 dropout = 0.5 num_epochs = 50 optimizer = ADAM

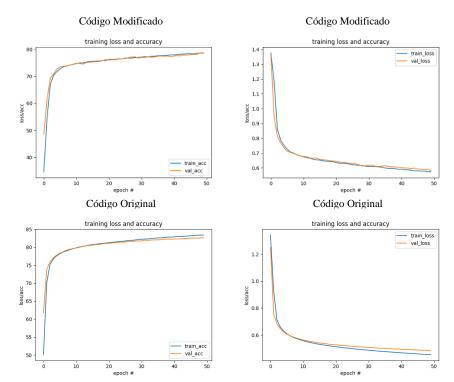
> Modificação: features = torch.mean(output, dim=1)



Comentários: A habilitação do dropout praticamente não trouxe melhorias no modelo.

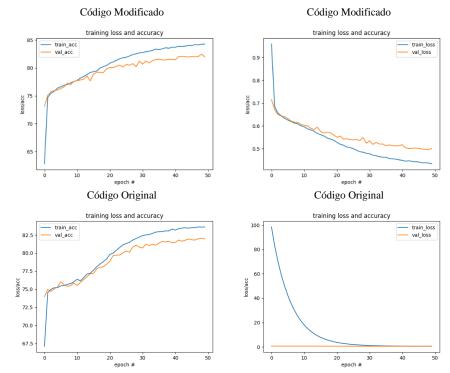
Test loss: 0.46459209663527373 Test Accuracy: 83.27566964285717

9 embedding_size = 100 hidden_dim = 200 batch_size = 128 learning_rate = **0.00001** dropout = (desabilitado) num_epochs = 50 optimizer = ADAM



Comentários: Os resultados de ambos os modelos foram praticamente os mesmos.

Test loss: 0.5759246660130368 Test Accuracy: 78.60491071428571 13 embedding_size = 100 hidden_dim = **200** batch_size = 128 learning_rate = **0.0001** dropout = 0.5 num_epochs = 50 optimizer = ADAM l2_regularization = 0.001

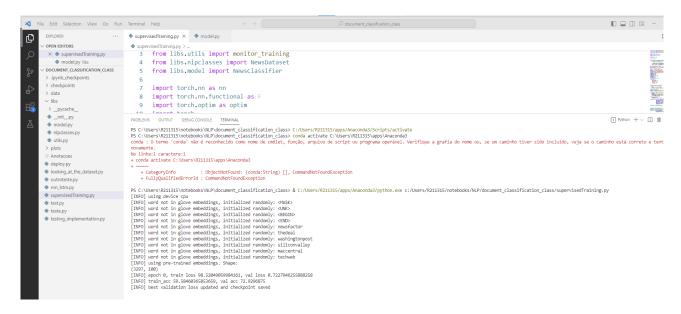


Comentários: Com o modelo modificado, a perda de validação deixou de ficar sempre zerada. Este foi o melhor resultado obtido.

Test loss: 0.48753383862120775 Test Accuracy: 82.26562500000001

Observações:

Executamos o treinamento dos modelos em máquinas locais, utilizando o VSCode.



Também utilizamos o Google Colab, conseguindo utilizar basicamente a mesma estrutura de pasta do projeto.

